
MVP ИИ-аналитики корпоративного хранилища данных

Архитектура, план реализации и перспективные инициативы

Домашнее задание на позицию инженера по искусственному интеллекту

Кругликовский Павел Александрович

Июль 2026 года

Работающий образец системы, набор проверок и исходный код:
github.com/devAsmodeus/dwh-copilot

Содержание

Раздел	Стр.
Краткое изложение решения	3
Часть 1. Архитектура MVP	
1.1. Архитектурная схема	4
1.2. Путь одного вопроса	6
1.3. Обоснование выбора компонентов	7
1.4. Ответы на отдельные вопросы задания	11
1.5. Состав проверки SQL	13
1.6. Размещение данных по памяти	15
1.7. Отказоустойчивость и эксплуатация	17
1.8. План реализации и оценка трудозатрат	19
Часть 2. Перспективные инициативы	
2.1. Портфель инициатив	22
2.2. Инициатива А. Ассистент разработчика 1С	23
2.3. Инициатива В. Прогноз спроса и рекомендации закупок	25
2.4. Инициатива С. Оптимизация загрузки транспорта	27
2.5. Обязательный вопрос: одна инициатива на весь бюджет	29
Приложение. Что уже реализовано и проверено	31

Краткое изложение решения

Предлагается система, которая принимает вопрос на русском языке, формирует запрос к корпоративному хранилищу на Microsoft SQL Server, проверяет его на безопасность, выполняет под учётной записью только для чтения и возвращает текстовый вывод, таблицу и график. Работа идёт полностью внутри корпоративного контура: модель размещена локально, обращений к внешним службам нет.

Три решения, определяющие результат

Прямолинейный подход, при котором модели подаётся схема базы данных и она пишет запрос, даёт около половины верных ответов и не выдерживает промышленной эксплуатации. В предлагаемом решении приняты три меры, меняющие исход.

- 1. Модель не видит схему хранилища.** Она работает с семантическим слоем из 50 представлений, внутри которых бизнес-логика уже закреплена человеком. Вместо соединения четырёх таблиц модель пишет группировку по одной витрине. Сложность перенесена туда, где она проверяема.
- 2. Перечень разрешённых объектов не является кодом приложения.** Это система прав СУБД. Ошибку в коде проверки допустить можно, запрет на базовые таблицы на уровне СУБД обойти нельзя.
- 3. Качество измеряется числом, а не мнением.** Набор из 25 бизнес-вопросов с эталонными запросами прогоняется автоматически при каждом изменении текста подсказки, манифеста витрин или версии модели. Снижение доли верных ответов блокирует приём изменения.

Состав решения

Слой	Выбор	Ключевое основание
Интерфейс	Веб-приложение, далее чат-бот в Битрикс24	Битрикс выступает транспортом, а не источником данных
Языковая модель	Qwen3-30B-A3B, разреженная, INT4	Качество уровня 32B при скорости 3B, помещается в 32 ГБ вместе с кэшем
Сервер вывода	vLLM	Кэш префикса, ограничение грамматикой, выдача метрик
Семантический слой	50 представлений схемы mart	Бизнес-логика в SQL, а не в подсказке модели
Проверка запроса	Разбор в дерево, sqlglot, шесть рубежей	Отказ по умолчанию, три независимых уровня защиты
Хранилище	Microsoft SQL Server, учётная запись чтения	DENY на базовые таблицы, отдельный пул ресурсов
Оценка качества	25 бизнес-вопросов, совпадение данных	Автоматический прогон при каждом изменении

Готовность на момент сдачи

Собран работающий образец: развёртывание одной командой, демонстрационное хранилище с 14 витринами, 52 автоматические проверки, набор из 25 бизнес-вопросов. Оба примера вопросов из задания выполнены на стенде. Подробности в приложении.

Часть 1. Архитектура MVP ИИ-аналитики

1.1. Архитектурная схема

Схема отражает все элементы, перечисленные в задании: пользовательский интерфейс, авторизацию, сервер вывода языковой модели, саму модель, слой формирования SQL, источник метаданных хранилища, проверку SQL, перечень разрешённых объектов, хранилище на Microsoft SQL Server, формирование текстового ответа, таблицы и графика, журналирование и аудит, мониторинг служб и оборудования.




Рисунок 1. Архитектура системы

Существенная особенность схемы: между приложением и базовыми таблицами хранилища нет пути. Учётная запись, под которой работает приложение, видит только представления схемы mart. Это не соглашение и не проверка в коде, а запрет на уровне СУБД, который не снимается ошибкой в приложении.

1.2. Путь одного вопроса

Вопрос: "Покажи динамику продаж по регионам за последние три месяца"

- |
- | 1. Резолвер периодов, обычный код, без модели
- | "последние три месяца" -> 28.04.2026 .. 28.07.2026
- | отсчёт от даты актуальности данных, а не от сегодняшней
- v
- | 2. Отбор витрин и примеров, процессор, менее 50 мс
- | 8 витрин из 50, 4 примера запросов
- v
- | 3. Обращение к модели номер 1: формирование запроса
- | постоянная часть подсказки взята из кэша префикса
- v
- | 4. Проверка SQL, рубежи 1-4
- | отклонён -> причина возвращается модели, до 2 повторов
- v
- | 5. Оценка стоимости до выполнения, рубеж 5
- | слишком дорого -> причина возвращается модели
- v
- | 6. Выполнение под учётной записью чтения, рубеж 6
- | не более 10 000 строк, ограничение времени 30 секунд
- v
- | 7. Выбор вида графика по правилу, обычный код, без модели
- v
- | 8. Обращение к модели номер 2: текстовый вывод
- | передаётся не более 100 строк результата
- v

Ответ: текст, таблица, график, код обращения для журнала аудита

Обращений к модели в основном сценарии: два.

Повторы происходят только при отказе и ограничены двумя.

Рисунок 2. Обработка вопроса по шагам

Два шага выполняются обычным кодом, а не обращением к модели, и это сознательное решение. Разбор относительных периодов и выбор вида графика решаются двумя десятками строк детерминированного кода. Передача этих задач модели добавила бы к времени ответа около полутора секунд на каждую и создала бы дополнительные точки отказа: модель может вернуть ссылку на несуществующую колонку или неверный формат, и это пришлось бы обрабатывать.

1.3. Обоснование выбора компонентов

Языковая модель: Qwen3-30B-A3B

Назначение. Формирование запросов на языке T-SQL и текстовых выводов по полученным данным.

Почему выбрана. Ключевое ограничение задачи заключается не в объёме памяти ускорителя, а в её распределении. Доступно 32 гигабайта, и в них должны поместиться и веса модели, и кэш контекста на 5-10 одновременных сессий. Кэш контекста обычно упускают из расчёта, и именно он определяет выбор.

Вариант	Веса, INT4	Кэш контекста 10 сессий по 8 тыс. токенов	Итого
Qwen3-32B, плотная, кэш FP16	19 ГБ	20 ГБ	39 ГБ, не помещается
Qwen3-32B, плотная, кэш FP8	19 ГБ	10 ГБ	29 ГБ, впритык
Qwen3-30B-A3B, разреженная, кэш FP8	18 ГБ	8 ГБ	26 ГБ, с запасом

Разреженная модель, в англоязычной литературе *mixture of experts*, то есть смесь экспертов, содержит 30 миллиардов параметров, но на обработку каждого слова задействует 3,3 миллиарда. Это даёт качество уровня плотной модели на 32 миллиарда при скорости уровня модели на 3 миллиарда. При 5-10 одновременных пользователях на одном ускорителе это не оптимизация, а смена класса решения.

Дополнительное основание: лицензия Apache 2.0. Это снимает вопрос юридического согласования для внутрикорпоративного применения.

Рассмотренные альтернативы.

Вариант	Причина отклонения
Gemma 3 27B	Лицензия Gemma Terms of Use содержит ограничения использования и не одобрена организацией Open Source Initiative. Требуется юридическое согласование. Слабее на задачах T-SQL
Llama 3.3 70B	Не помещается в 32 гигабайта даже при четырёхбитном квантовании
Qwen2.5-Coder-32B	Оставлена запасным вариантом. Проверенное качество на SQL, но плотная архитектура даёт меньшую пропускную способность при одновременных обращениях
Mistral Small 3.2 24B	Помещается, но уступает по качеству на русском языке и на T-SQL

Порядок выбора. Модель не выбирается по опубликованным сравнениям. Три кандидата прогоняются на наборе из 25 бизнес-вопросов, решение принимается по доле верных ответов, определяемой совпадением данных. Это работа объёмом в два дня, и она окупается: расхождение между опубликованными сравнениями и поведением на конкретной схеме данных достигает десятков процентов.

Отмеченный риск. Видеокарта RTX 5090 построена на архитектуре Blackwell с вычислительной способностью 12.0. Программные ядра для четырёхбитных вычислений под эту архитектуру появились в vLLM недавно. Проверка выполняется на стенде в первую неделю, до начала остальной разработки. Запасной вариант: формат FP8 поддерживается архитектурой Blackwell на аппаратном уровне, при отказе от INT4 применяется Qwen3-14B в формате FP8.

Опыт кандидата. Разворачивал локальные модели через Ollama и LM Studio, поднимал открытые модели, включая Hermes и Kimi, работал с открытыми агентными средствами, в том числе OpenClaw. Ежедневно применяю ассистенты разработки в работе и отслеживаю развитие инструментов.

Сервер вывода: vLLM

Назначение. Обслуживание обращений к языковой модели.

Почему выбран. Четыре возможности, каждая из которых требуется по условиям задачи.

- Кэширование префикса.** Постоянная часть подсказки, около 1500 слов в машинном представлении, одинакова для всех вопросов. Сервер сохраняет результат её обработки и переиспользует при следующих обращениях. При 10 пользователях это разница между ответом за 3 секунды и за 12.
- Ограничение вывода грамматикой.** Механизм `xgrammar` позволяет запретить формирование синтаксически неверного T-SQL на этапе генерации. Это нулевой рубеж защиты, получаемый без дополнительных затрат.
- Страничное управление памятью контекста.** Механизм `PagedAttention` позволяет разместить 10 сессий в оставшемся объёме памяти ускорителя без резервирования максимального контекста под каждую.

4. **Выдача метрик.** Точка /metrics закрывает требование задания по мониторингу служб без написания дополнительного кода.

Рассмотренные альтернативы.

Вариант	Причина отклонения
LM Studio	Настольное приложение с графическим интерфейсом. Нет точки выдачи метрик, нет полноценной контейнеризации, нет автоматического кэширования префикса, слабая пакетная обработка одновременных обращений. Оставлено как средство локальных опытов, но не как составная часть промышленной установки
Ollama	Проще в развёртывании, но заметно ниже пропускная способность при одновременных обращениях, нет ограничения вывода грамматикой
SGLang	Сопоставим с vLLM по возможностям. Оставлен равноценной заменой на случай затруднений с поддержкой архитектуры Blackwell
TensorRT-LLM	Наибольшая скорость, но сборка под каждую модель занимает часы и усложняет обновление. Избыточно для 20 пользователей

Опыт кандидата. Развёртывание локальных серверов вывода, подбор параметров под доступный объём памяти ускорителя.

Семантический слой вместо схемы хранилища

Назначение. Преобразование вопроса на русском языке в запрос к хранилищу.

Главное решение всей архитектуры. Модель формирует запрос не по схеме хранилища, а по семантическому слою из 50 представлений схемы mart. Бизнес-логика расчёта показателей закреплена внутри представлений.

Три следствия, каждое из которых закрывает отдельное требование задания.

1. **Перечень разрешённых объектов перестаёт быть кодом приложения и становится системой прав СУБД.** Ошибку в коде проверки допустить можно, запрет DENY на базовые таблицы обойти нельзя. Это принципиально другой класс защиты.
2. **Определение показателя становится единственным.** Внутри представления уже записано, что выручка считается без налога на добавленную стоимость и за вычетом возвратов. Положение, при котором выручка в одном отчёте не сходится с выручкой в другом, становится невозможным по построению.
3. **Формируемые запросы становятся проще.** Локальная модель уверенно пишет группировку по одной витрине и заметно чаще ошибается в соединении четырёх таблиц. Сложность перенесена в SQL, написанный и проверенный человеком.

Второй пример вопроса из задания, о подразделениях с фактической выручкой ниже плана более чем на 10 процентов, служит прямым указанием на витрину со сведёнными планом и фактом. Соединять план с фактом запросом, который формирует модель, означает заведомо проигрышный путь: в этом соединении модель ошибается чаще всего.

Опыт кандидата. Строил общий слой бизнес-метрик на Microsoft SQL Server для последующего анализа, то есть то же решение, что лежит в основе предлагаемой архитектуры. Оптимизировал запросы, разбирал качество справочников и расхождения в отчётности.

Интерфейс пользователя

Замечание по заданию. В перечне того, что входит в MVP, указан чат-бот в Битрикс24 как предпочтительный интерфейс. В перечне того, что в MVP не входит, указана интеграция с Битрикс24. Противоречие разрешается разделением понятий: Битрикс выступает **транспортом**

сообщений через открытые линии и единый вход, но не является **источником данных**. Обращений к сущностям Битрикса, то есть к сделкам, задачам и контактам, система не выполняет.

Порядок работ. На первом этапе разворачивается веб-приложение: оно нужно для отладки, для прогона набора бизнес-вопросов и для показа заказчику. Бот в Битриксе подключается на пятой неделе как дополнительный канал к тому же программному интерфейсу. Такой порядок снижает риск: затруднения с настройкой открытых линий не блокируют основную разработку.

1.4. Ответы на отдельные вопросы задания

Нужно ли передавать модели всю схему хранилища

Нет. Модель работает с семантическим слоем, а не со схемой. При 50 витринах их полные описания дают 10-12 тысяч слов в машинном представлении, и качество формирования запросов падает. Причина не в стоимости обработки, которую снимает кэширование префикса, а в том, что при большом объёме нерелевантного текста модель хуже находит нужные таблицы. Явление известно как потеря в середине контекста и воспроизводится на всех современных моделях.

Описание подаётся в двух видах.

Вид	Объём	Когда подаётся
Компактный указатель: имя и одна строка назначения по каждой из 50 витрин	около 900 единиц	Всегда и целиком, попадает в кэшируемую часть подсказки
Полное описание: колонки, типы, связи, примеры значений категориальных полей	около 1600 единиц	Только по 8 витринам, отобранным под конкретный вопрос

Компактный указатель остаётся в подсказке намеренно. Он даёт модели возможность обнаружить существование подходящей витрины, подробности по которой в этот раз не подавались, и сообщить об этом. Без него отказ отбора приводил бы к тому, что модель придумывает названия.

Как работать, если в хранилище более 200 таблиц

Число базовых таблиц на архитектуру не влияет: модель их не видит и прав на них не имеет. Значение имеет число витрин.

При росте до нескольких сотен витрин схема выдерживает нагрузку без изменений: компактный указатель растёт линейно и остаётся в пределах 3-4 тысяч единиц, а подробности подаются по неизменному числу отобранных витрин. При выходе за эти пределы указатель делится по предметным областям, и отбор становится двухступенчатым: сначала область, затем витрины внутри неё.

Отбор выполняется поиском по смысловой близости, а не дополнительным обращением к модели. Отдельное обращение добавило бы к времени ответа полторы-две секунды, тогда как поиск по 50 записям на процессоре занимает менее 50 миллисекунд.

Как обновлять метаданные при изменении схемы

Ночная сверка. Задание сравнивает состав колонок в системном представлении INFORMATION_SCHEMA с манифестом витрин. Расхождение порождает оповещение. Несовместимое изменение, например удаление или переименование колонки, приводит к автоматическому выводу витрины из перечня разрешённых объектов до ручной вычитки.

Принцип, определяющий это поведение: отказать лучше, чем молча выдать неверную цифру. Система, которая после изменения схемы продолжает отвечать, опираясь на устаревшее

описание, опаснее системы, которая отвечает отказом.

Где хранить бизнес-словарь и примеры SQL

В системе контроля версий, как код. Манифесты в формате YAML лежат рядом с определениями представлений, проходят обязательную проверку изменений и покрыты автоматическими проверками.

Вариант хранения	Оценка
Система контроля версий	Принято. Есть история изменений, обязательное рецензирование, автоматическая проверка. Изменение определения выручки видно в истории с указанием автора и основания
Корпоративная вики	Отклонено. Нет обязательной проверки изменений, содержимое устаревает и расходится с действительностью
Таблица в базе данных	Отклонено. Изменение эталонного примера не проходит рецензирование, а ошибка в нём распространяется на все последующие ответы модели

Банк примеров пополняется в ходе эксплуатации: ответ, проверенный и подтверждённый аналитиком, добавляется в файл обычным запросом на слияние. Система становится точнее по мере использования, и рост качества виден на наборе бизнес-вопросов как измеримая величина.

1.5. Состав проверки SQL

Исходное допущение. Языковая модель считается недоверенным источником. Проверка строится так, как если бы модель была полностью скомпрометирована и формировала произвольный текст запроса.

Из этого следует важное правило: попытки подменить инструкции через текст вопроса не фильтруются на входе. Способов переформулировать такую попытку бесконечно много, и фильтрация входа является тупиковым путём. Вместо этого система построена так, что успешная подмена ничего не даёт: сформированный запрос к закрытой схеме не пройдёт белый список, а если бы прошёл, у учётной записи нет прав на эту схему.

УРОВЕНЬ ГЕНЕРАЦИИ

- Рубеж 0 Ограничение грамматикой T-SQL на сервере vLLM
Синтаксически неверный запрос не может быть сформирован

УРОВЕНЬ ПРИЛОЖЕНИЯ

- Рубеж 1 Разбор в синтаксическое дерево, sqlglot, диалект tsq1
Не разобралось -> отказ (принцип отказа по умолчанию)
- Рубеж 2 Структурные правила по дереву:
 ровно одна инструкция блокирует ";" DROP TABLE"
 корневой узел = SELECT блокирует запись
 нет имён из четырёх частей блокирует другие серверы
 нет соединения без ON блокирует декартово произведение
 нет узлов INTO, EXEC, блокирует запись под видом
 OPENROWSET, OPENQUERY чтения и внешние источники
- Рубеж 3 Белый список по дереву
Обход ВСЕХ узлов Table, включая подзапросы и выражения WITH
- Рубеж 4 Принудительное TOP 10000, вставка в дерево, не в текст
- Рубеж 5 Оценка стоимости ДО выполнения, SET SHOWPLAN_XML ON
строк > 1 млн ИЛИ стоимость > порога -> отказ

УРОВЕНЬ СУБД

- Рубеж 6 Отдельная учётная запись только для чтения
 DENY SELECT ON SCHEMA::dbo базовые таблицы закрыты
 GRANT SELECT ON SCHEMA::mart только витрины
 DENY VIEW ANY DEFINITION состав объектов скрыт
 Ограничение времени выполнения 30 секунд
 Resource Governor: отдельный пул CPU и памяти

ПОСТОБРАБОТКА

- Рубеж 7 Обрезка до предельного числа строк
Маскирование текста ошибок СУБД для пользователя

Рисунок 3. Рубежи защиты

Уровни независимы. Обход одного не даёт обхода остальных: полная компрометация приложения упирается в права СУБД.

Почему не применяется поиск по тексту запроса

Проверка по перечню запрещённых слов обходится тривиально вставкой комментария внутрь слова. Но основная проблема не в обходах. Поиск по тексту отвечает только на вопрос, есть ли в запросе запрещённые слова. Нужный вопрос звучит иначе: к каким объектам базы данных обращается этот запрос. На него отвечает только разбор в синтаксическое дерево.

Оценка стоимости как отдельный рубеж

Два вида запросов проходят любой статический анализ: выборка без агрегации из крупной витрины и соединение двух разрешённых витрин по неудачному условию. Оба полностью законны: объекты верные, синтаксис чистый, белый список пройден. Различие проявляется только в стоимости выполнения.

Microsoft SQL Server умеет вернуть оценочный план, не выполняя запрос. Из плана берутся оценочное число строк и оценочная стоимость. Превышение порога приводит к отказу, причина которого передаётся модели, и она переписывает запрос сама. Защита становится экономической, а не синтаксической: запрос отсекается не за то, как написан, а за то, сколько будет стоить.

Обращение с сообщениями об ошибках

Текст ошибки СУБД пользователю не показывается. Сообщение вида Invalid object name подтверждает наличие или отсутствие объекта в хранилище, а серия таких вопросов раскрывает структуру закрытых схем. Пользователю показывается обобщённая формулировка и код обращения. Полный текст записывается в журнал и передаётся модели: модель является единственным участником, способным исправить собственный запрос.

Опыт кандидата. Разработка на T-SQL, разбор планов выполнения, оптимизация запросов, настройка прав доступа.

1.6. Размещение данных по памяти

Носитель	Что размещается	Объём
Память ускорителя 32 ГБ	Веса модели в формате INT4 Кэш контекста активных сессий, формат FP8 Кэш префикса подсказки Резерв на пиковую нагрузку	18 ГБ 8 ГБ менее 1 ГБ 5 ГБ
Оперативная память 128 ГБ	Приложение и веб-интерфейс Модель эмбедингов BGE-M3 и векторный индекс описаний витрин Результаты запросов на время обработки Свободно под кэш файловой системы	2 ГБ 3 ГБ до 4 ГБ остальное
Накопитель 1,92 ТБ	Веса двух моделей, основной и запасной Образы контейнеров Журналы аудита и ошибок, хранение 180 дней Метрики, хранение 90 дней Резервные копии настроек и манифестов	40 ГБ 25 ГБ 30 ГБ 20 ГБ 5 ГБ

Загружаются ли данные хранилища в память ускорителя

Нет, и это невозможно по построению. В модель попадает только текст подсказки и не более ста строк результата на шаге формирования текстового вывода. Содержимое хранилища в память ускорителя не помещается ни при каких условиях: между СУБД и ускорителем нет пути передачи данных, минуя приложение, а приложение ограничивает объём.

Какие результаты запросов передаются модели

Не более ста строк, и только на шаге формирования текстового вывода. Полная таблица передаётся в интерфейс пользователя, минуя модель. Для вывода вида «выручка выросла на 12 процентов, основной вклад дал Северо-Запад» ста строк достаточно с большим запасом: осмысленный аналитический ответ строится по агрегированным данным, а не по детальным.

Как исключается передача модели миллионов строк

Тремя независимыми ограничениями, каждое из которых достаточно само по себе.

1. **Оценка стоимости до выполнения, рубеж 5.** Отказ при оценке свыше миллиона строк. Запрос не выполняется вовсе.
2. **Принудительное ограничение TOP 10000, рубеж 4.** Вставляется в синтаксическое дерево запроса, а не приклеиванием текста. Склейка строк ломается на любом нетривиальном запросе и обходится комментарием.
3. **Отсечение до ста строк перед передачей в модель.** Выполняется приложением независимо от того, сколько строк вернула СУБД.

Как очищаются временные данные после выполнения запроса

Результат запроса существует в оперативной памяти в пределах обработки одного вопроса и освобождается сборщиком мусора после отправки ответа. На диск результаты не записываются, временные таблицы в хранилище не создаются: конструкция SELECT INTO входит в перечень запрещённых на рубеже 2.

В журнал аудита попадают текст вопроса, отобранные витрины, все попытки формирования запроса, выполненный запрос, число строк и время выполнения. Сами данные в журнал не попадают. Это существенно: журнал хранится 180 дней и доступен более широкому кругу лиц, чем сами витрины.

Кэш префикса подсказки на сервере вывода содержит только описания витрин и правила формирования запросов. Данных хранилища в нём нет, поэтому его сохранение между обращениями не создаёт риска.

1.7. Отказоустойчивость и эксплуатация

Подход соразмерен задаче: 20 пользователей, один сервер, внутренний инструмент аналитики. Резервирование сервера и горячее переключение не предлагаются, поскольку недоступность системы на несколько часов не останавливает бизнес-процессы. Предлагается быстрое восстановление, а не непрерывность.

Резервное копирование

Что копируется	Периодичность	Хранение	Замечание
Настройки, манифесты витрин, банк примеров, текст подсказки	При каждом изменении	Бессрочно	Находятся в системе контроля версий, отдельного копирования не требуют
Журнал аудита и история диалогов	Ежедневно	180 дней	Отдельная база, не входит в хранилище
Веса моделей	При смене версии	Две последние версии	40 ГБ, восстановление быстрее повторной загрузки из сети
Образы контейнеров	При выпуске версии	Пять последних	Реестр образов, возможность отката одной командой
Хранилище данных	Не копируется		Копирование выполняется службой сопровождения КХД, система является только читателем

Восстановление служб

Все службы описаны в одном файле развёртывания и запускаются одной командой. Полное восстановление на чистом сервере состоит из трёх шагов: получить репозиторий, восстановить файл настроек из хранилища секретов, запустить развёртывание. Веса моделей подтягиваются из локального хранилища.

Целевое время восстановления: 30 минут при сохранности накопителя, 2 часа при замене оборудования. Проверка восстановления выполняется раз в квартал на отдельном стенде, а не считается достигнутой по описанию.

Обновление языковой модели

Обновление модели рассматривается как изменение, влияющее на качество, и проходит ту же проверку, что и правка кода.

1. Новая модель разворачивается на отдельном порту, рядом с действующей.
2. Прогоняется набор из 25 бизнес-вопросов, результат сравнивается с действующим.
3. При росте или сохранении доли верных ответов трафик переключается изменением одного параметра.

4. Прежняя модель остаётся на диске две недели, откат занимает минуту.

Без этого порядка обновление модели превращается в лотерею: новая версия может улучшить одни вопросы и ухудшить другие, и без измерения это обнаружится только по жалобам пользователей.

Обновление контейнеров

Образы собираются автоматически при выпуске версии и помечаются номером версии, а не меткой latest. Развёртывание фиксирует конкретную версию, что делает откат предсказуемым. Обновления библиотек отслеживаются автоматически и поступают еженедельно в виде запросов на слияние, каждый из которых проходит полный набор проверок, включая набор бизнес-вопросов.

Мониторинг оборудования и служб

Что наблюдается	Источник	Порог оповещения
Загрузка, температура и занятая память ускорителя	DCGM exporter	Память свыше 95 процентов, температура свыше 85 градусов
Процессор, оперативная память, накопитель	node exporter	Свободное место менее 15 процентов
Время ответа модели, глубина очереди, попадания в кэш префикса	Точка /metrics сервера vLLM	95-й перцентиль времени ответа свыше 20 секунд
Доля отказов проверки запросов	Метрики приложения	Свыше 30 процентов за час
Время выполнения запросов в СУБД	Метрики приложения	95-й перцентиль свыше 10 секунд
Ошибки приложения	Журнал в Loki	Появление ошибки уровня error
Доля верных ответов на контрольном наборе	Ночной прогон	Падение более чем на 5 процентных пунктов

Последняя строка заслуживает отдельного внимания. Обычный мониторинг показывает, что система работает, но не показывает, что она отвечает верно. Ночной прогон контрольного набора закрывает этот разрыв: качество деградирует незаметно при изменении данных в хранилище, и без регулярного измерения это обнаруживается поздно.

Журналирование ошибок и контроль времени ответа

По каждому обращению записывается: код обращения, пользователь, текст вопроса, отобранные витрины, все попытки формирования запроса с их результатами, выполненный запрос, число строк, время каждого шага. Разделение времени по шагам позволяет отличить медленную модель от медленного запроса, а это разные неисправности с разными решениями.

Целевые значения времени ответа: медиана не выше 8 секунд, 95-й перцентиль не выше 20 секунд. Именно 95-й перцентиль вынесен в оповещения: пользователь запоминает худший случай, а не типичный.

Хранение истории диалогов

История хранится в отдельной базе, а не в корпоративном хранилище. Состав: вопросы, сформированные запросы, метаданные ответов. Сами данные ответов не сохраняются, поскольку они воспроизводимы повторным выполнением запроса, а их хранение создало бы копию содержимого хранилища вне действия его ролевой модели.

Срок хранения 180 дней. История служит трём целям: разбор обращений пользователей, пополнение банка примеров подтверждёнными ответами, выявление вопросов, на которые система отвечает плохо.

1.8. План реализации и оценка трудозатрат

Длительность 8 недель. Состав команды: инженер по искусственному интеллекту на полной занятости, аналитик корпоративного хранилища на половинной занятости, инженер сопровождения на четверти занятости, представитель бизнеса для приёмки.

Порядок этапов определён снижением риска, а не удобством разработки. Проверка совместимости оборудования вынесена в первую неделю: обнаружить несовместимость на шестой неделе означает потерять проект.

Этап	Срок	Результат	Критерий приёмки	Риск
1. Проверка оборудования и выбор модели	Неделя 1	Развёрнут vLLM на RTX 5090, три модели-кандидата запущены, замерена скорость при 10 одновременных обращениях	Модель отвечает, скорость не ниже 20 слов в секунду на сессию при 10 сессиях	Ядра INT4 под архитектуру Blackwell. Запасной вариант: FP8 и модель меньшего размера
2. Семантический слой	Недели 2-3	Определены и созданы 50 витрин, заполнен манифест с описаниями, связями и примерами значений	Все 50 витрин доступны учётной записи чтения, ночная сверка со схемой проходит	Готовность аналитика КХД. Это узкое место всего проекта, требуется выделенное время
3. Контрольный набор вопросов	Неделя 3	25 бизнес-вопросов с эталонными запросами, зафиксирован снимок данных	Все эталонные запросы проходят проверку безопасности и выполняются на снимке	Разногласия бизнеса о том, что считать верным ответом. Снимаются письменным согласованием
4. Проверка SQL и права доступа	Неделя 4	Реализованы рубежи 1-6, настроены права и пул ресурсов	Набор проверок на нарушения проходит полностью, самопроверка прав завершается успешно	Низкий. Работа предсказуемая
5. Слой формирования SQL	Недели 4-5	Отбор витрин, сборка подсказки, цикл исправления запроса	Доля верных ответов не ниже 50 процентов на контрольном наборе	Основной риск проекта. Снижается банком примеров и уточнением описаний витрин
6. Веб-интерфейс и виды вывода	Неделя 5	Текст, таблица, график, раскрытие хода обработки	Оба примера вопросов из задания отрабатывают от начала до конца	Низкий
7. Подъём качества	Недели 6-7	Пополнение банка примеров, уточнение описаний витрин, доработка правил	Доля верных ответов не ниже 70 процентов, 95-й процентиль времени ответа не выше 20 секунд	Упор в предел возможностей модели. Снижается расширением семантического слоя, а не правкой подсказки

Этап	Срок	Результат	Критерий приёмки	Риск
8. Наблюдаемость, эксплуатация, опытный запуск	Неделя 8	Панели, оповещения, резервное копирование, подключение бота Битрикс24, 5 пользователей в опытной эксплуатации	Оповещения срабатывают на учебном отказе, восстановление проверено на стенде	Настройка открытых линий Битрикс24. Не блокирует: веб-интерфейс остаётся основным каналом

Оценка трудозатрат. Инженер по искусственному интеллекту 8 недель полной занятости, что составляет 320 часов. Аналитик КХД 4 недели половинной занятости, 80 часов, из них основная часть приходится на описание витрин. Инженер сопровождения 2 недели четверти занятости, 20 часов. Итого около 420 человеко-часов.

Главный риск срока. Не разработка, а готовность аналитика КХД на втором и третьем этапах. Описание 50 витрин с указанием трактовок по умолчанию и примеров значений требует человека, знающего предметную область, и не может быть выполнено инженером самостоятельно. При отсутствии выделенного времени аналитика срок сдвигается на две-три недели независимо от прочих обстоятельств.

Что сокращается при нехватке времени. В порядке очередности: бот в Битрикс24, часть витрин с 50 до 25, подъём качества с недели 7 переносится в эксплуатацию. Не сокращаются: проверка SQL, права доступа и контрольный набор вопросов. Система без измерения качества неотличима от неработающей.

Часть 2. Перспективные инициативы

2.1. Портфель инициатив

Инициативы подобраны так, чтобы они различались по уровню риска, а не были тремя одинаково крупными замыслами. Такой состав позволяет запустить работу сразу, не дожидаясь результата длительного пилота, и получить измеримый результат в первом квартале.

	Инициатива	Риск	Срок пилота	Ожидаемый эффект
A	Ассистент разработчика 1С	Низкий	4-6 недель	Средний, наступает быстро
B	Прогноз спроса и рекомендации закупок	Высокий	3-4 месяца	Наибольший из трёх
C	Оптимизация загрузки транспорта	Средний	2-3 месяца	Средний, считается точно

Обучение пользователей не выделено в отдельную инициативу намеренно. Оно является частью каждой из трёх: инструмент, которым не умеют пользоваться, не даёт эффекта независимо от качества. Управление изменениями заложено в срок каждого пилота отдельной строкой.

2.2. Инициатива А. Ассистент разработчика 1С

Бизнес-проблема	Доработки конфигураций выполняются вручную. Значительная доля времени разработчика уходит на типовые операции: разбор чужого кода, написание обработчиков по образцу, подготовка запросов. Новый разработчик выходит на рабочую производительность за два-три месяца, поскольку знание конфигурации не документировано и передаётся от человека к человеку.
Целевые пользователи	Разработчики 1С внутренней группы разработки, аналитики, ставящие задачи на доработку
Сценарий работы	Разработчик обращается к ассистенту прямо в среде разработки либо через тот же веб-интерфейс: просит объяснить назначение фрагмента кода, предложить реализацию по описанию задачи, найти похожие места в конфигурации, составить запрос на встроенном языке запросов. Ответы опираются на код конкретной конфигурации, а не на общие сведения
Источники данных	Выгрузка конфигурации в файлы, история изменений в системе контроля версий, внутренние стандарты разработки, база решённых задач
Необходимые ИИ-компоненты	Локальная языковая модель для кода, поиск по коду конфигурации с помощью эмбедингов, векторное хранилище. Дообучение на первом этапе не требуется
Возможность локальной реализации	Обязательна, и это главное основание инициативы. Код конфигураций содержит бизнес-логику компании и является объектом интеллектуальной собственности. Отправлять его в облачный сервис нельзя. Это тот редкий случай, когда локальная модель не является уступкой, а остаётся единственным допустимым вариантом
Основные риски	Языки 1С представлены в обучающих наборах открытых моделей заметно хуже распространённых языков программирования, поэтому качество на первом этапе будет ниже привычного по универсальным ассистентам. Снижается подачей фрагментов конфигурации в запрос и подбором примеров. Второй риск: сопротивление разработчиков. Снижается добровольным участием на пилоте
Ожидаемый эффект	Сокращение времени на типовую доработку на 20-30 процентов. Сокращение срока выхода нового разработчика на производительность с трёх месяцев до полутора. Побочный эффект: описание конфигурации, накопленное в процессе, остаётся у компании
Метрики успеха	Среднее время выполнения задачи типовой сложности до и после. Доля принятых предложений ассистента. Число обращений на разработчика в неделю. Срок выхода нового сотрудника на производительность
Сложность	Низкая. Инфраструктура MVP уже оплачена и развёрнута
Срок пилота	4-6 недель. Два разработчика на добровольной основе, сравнение с контрольной группой
Опыт кандидата	Разработкой на 1С не занимался: платформенная экспертиза требуется со стороны группы разработки, что отражено в составе команды пилота. Вклад приходится на часть, связанную с искусственным интеллектом: развёртывание открытых моделей для кода локально, работа с агентными средствами, ежедневное применение ассистентов разработки и понимание того, где они дают выигрыш, а где создают ложную уверенность

Отдельное соображение о стоимости. Инициатива не требует дополнительных вложений в оборудование: применяется тот же сервер и тот же сервер вывода, что и для аналитики хранилища. Это делает её удобной для запуска параллельно с длительным пилотом по закупкам и замыкает историю вложений: сервер, приобретённый под аналитику, окупается вторым продуктом практически бесплатно.

2.3. Инициатива В. Прогноз спроса и рекомендации закупок

Бизнес-проблема	Решения о закупках принимаются на основании опыта закупщика и простых правил вида среднего расхода за прошлый период. Следствием являются одновременно избыточные запасы по одним позициям и нехватка по другим. Замороженные в неликвиде средства и упущенные продажи из-за отсутствия товара представляют собой два проявления одной причины
Целевые пользователи	Отдел закупок, руководитель категории, финансовая служба в части планирования оборотного капитала
Сценарий работы	Система еженедельно формирует рекомендацию по объёму закупки в разрезе позиций. Закупщик видит не только цифру, но и объяснение: какие факторы повлияли, каков прогноз спроса, каков текущий остаток и срок поставки. Может задать уточняющий вопрос обычным языком, например о последствиях повышения цены поставщиком, и получить пересчёт. Может отклонить рекомендацию с указанием основания, и это основание учитывается при дальнейшем обучении
Источники данных	История продаж за 24 месяца, остатки, справочник номенклатуры, сроки поставки, календарь акций и промо, признаки отсутствия товара в продаже. Все источники внутренние
Необходимые ИИ-компоненты	Ядро: классическое машинное обучение, а именно градиентный бустинг и модели временных рядов. Это не задача для языковой модели, и подавать её как таковую было бы неверно. Языковая модель применяется как интерфейс к прогнозу: объясняет закупщику логику рекомендации, отвечает на уточняющие вопросы, принимает возражения эксперта и выполняет пересчёт. Это осмысленное применение языковой модели, а не её использование ради присутствия в проекте
Возможность локальной реализации	Полностью локальная. Обучение моделей выполняется на имеющемся ускорителе в нерабочее время. Существенное уточнение: данные о рынке и ценах конкурентов, которые запрашиваются в такую задачу, вынесены за периметр пилота. Их сбор означает обращение к внешним источникам, что противоречит требованию работы в корпоративном контуре и создаёт правовые вопросы. Возврат к ним возможен на втором этапе с отдельным согласованием
Основные риски	Качество данных, и это риск первого порядка. История продаж искажена периодами отсутствия товара: модель обучается на продажах, а не на спросе. Дубли в справочнике номенклатуры превращают один товар в три разных. Неразмеченные акции воспринимаются как изменение тенденции. Каждая из этих причин по отдельности достаточна для провала пилота. Второй риск: недоверие закупщиков к рекомендации, которую они не понимают. Снижается требованием объяснимости каждой рекомендации
Ожидаемый эффект	Сокращение неликвидных запасов на 10-15 процентов, снижение доли отсутствующих в продаже позиций на 20-30 процентов. В денежном выражении эффект складывается из высвобожденного оборотного капитала и возвращённых продаж и является наибольшим среди трёх инициатив
Метрики успеха	Средняя абсолютная процентная ошибка прогноза против текущего порядка планирования. Оборачиваемость запасов по пилотной категории против контрольной. Доля рекомендаций, принятых закупщиком без изменений. Доля позиций, отсутствовавших в продаже
Сложность	Высокая
Срок пилота	3-4 месяца с промежуточными контрольными точками

Опыт кандидата	Работа с временными рядами в проектах по ценообразованию, что является методологически ближайшей задачей к прогнозу спроса. Построение слоя бизнес-метрик на корпоративном хранилище. Наблюдал типовые изъяны данных: дубли в справочниках, искажения в истории. Существенно: участвовал в проработке технического задания на рекомендательную систему закупок в текущей компании. Проект не стартовал по причине отсутствия в команде людей с нужными навыками, а не по причине недостаточного экономического обоснования. Этот опыт определил структуру предлагаемого плана: аудит данных вынесен в отдельную фазу с контрольной точкой, а состав команды расписан поимённо по ролям
----------------	---

2.4. Инициатива С. Оптимизация загрузки транспорта

Предварительное замечание, существенное для оценки инициативы. Ядро этой задачи не относится к искусственному интеллекту. Оптимальная укладка грузов представляет собой задачу трёхмерной упаковки, то есть классическую задачу комбинаторной оптимизации. Она решается специальными решателями, например библиотекой OR-Tools, и нейронные сети для неё не требуются и работают хуже решателя. Инициатива включена в перечень с этим уточнением, а не подана как задача искусственного интеллекта. Составляющая, относящаяся к искусственному интеллекту, находится на входе процесса.

Бизнес-проблема	Загрузка транспорта планируется вручную по опыту кладовщика. Заполнение объёма ниже возможного, что означает лишние рейсы. Габариты упаковок заносятся в учётную систему вручную, содержат ошибки и устаревают, поэтому любой расчёт по этим данным ненадёжен
Целевые пользователи	Кладовщики, логисты, руководитель склада
Сценарий работы	Короб проходит через пост измерения, где по фотографии определяются габариты и обновляются в справочнике. При формировании рейса решатель предлагает схему укладки с указанием порядка погрузки. Кладовщик видит схему на экране и может задать вопрос обычным языком о причине выбранного порядка
Источники данных	Справочник упаковок, заказы и их состав, характеристики транспорта, фотографии с поста измерения, история фактической загрузки рейсов
Необходимые ИИ-компоненты	Компьютерное зрение для определения габаритов по фотографии, то есть замена ручного занесения данных. Языковая модель как интерфейс кладовщика. Ядро задачи, а именно решатель трёхмерной упаковки, компонентом искусственного интеллекта не является, и это следует говорить прямо
Возможность локальной реализации	Полностью локальная. Модель компьютерного зрения работает на имеющемся оборудовании, решатель нагрузки на ускоритель не создаёт вовсе
Основные риски	Точность измерения по фотографии зависит от условий съёмки: освещения, фона, ракурса. Требуется оборудование поста измерения, что означает затраты вне области искусственного интеллекта. Второй риск: расхождение между расчётной схемой укладки и практикой погрузки, когда схема не учитывает порядок выгрузки по маршруту
Ожидаемый эффект	Повышение заполнения объёма транспорта на 8-12 процентов, что напрямую переводится в сокращение числа рейсов. Отдельный эффект: справочник габаритов приводится в достоверное состояние, а от него зависят и другие расчёты
Метрики успеха	Коэффициент заполнения объёма до и после. Число рейсов на единицу отгруженного объёма. Доля позиций с достоверными габаритами в справочнике. Время формирования рейса
Сложность	Средняя
Срок пилота	2-3 месяца, одно направление отгрузки
Опыт кандидата	Работал с логистическими и складскими данными. Есть опыт построения систем компьютерного зрения, что и составляет часть инициативы, относящуюся к искусственному интеллекту. Опыта работы с решателями комбинаторной оптимизации нет: требуется разработчик с соответствующей подготовкой, и это указано в составе команды

2.5. Обязательный вопрос: одна инициатива на весь бюджет

Выбор: инициатива В, прогноз спроса и рекомендации закупок, но с контрольными точками.

Основание выбора не сводится к наибольшему экономическому эффекту. Обе прочие инициативы дают эффект в границах одного подразделения, тогда как закупки определяют оборотный капитал компании в целом. Влияние на прибыль здесь на порядок выше.

Однако именно эта инициатива наиболее чувствительна к качеству данных из всех возможных, и большинство подобных пилотов прекращается по этой причине. Поэтому предлагается не запуск разработки, а запуск с контрольными точками.

ФАЗА 0. Аудит качества данных Проверяется: полнота истории продаж за 24 месяца доля позиций с корректной классификацией в справочнике размечены ли периоды отсутствия товара в продаже размечены ли акции и промо +-----+ КОНТРОЛЬНАЯ ТОЧКА: не пройдена -> пилот откладывается, запускается отдельный проект по приведению данных +-----+	2 недели
ФАЗА 1. Базовая модель на 100 позициях наибольшего спроса +-----+ КОНТРОЛЬНАЯ ТОЧКА: ошибка прогноза ниже, чем у текущего порядка планирования -> продолжаем +-----+	6 недель
ФАЗА 2. Объяснения и интерфейс закупщика	6 недель
ФАЗА 3. Опытная эксплуатация на одной категории +-----+ ПРИЁМКА: доля принятых без изменений рекомендаций и оборачиваемость против контрольной категории +-----+	4 недели

Рисунок 4. Порядок пилота с контрольными точками

Предполагаемый эффект

Высвобождение оборотного капитала за счёт сокращения неликвидных запасов на 10-15 процентов. Возвращённые продажи за счёт снижения доли отсутствующих в продаже позиций на 20-30 процентов. Точная величина в денежном выражении определяется по итогам фазы 0, когда становится известен объём достоверных данных.

Стоимость и срок

18 недель до завершения опытной эксплуатации. Дополнительных вложений в оборудование не требуется: обучение моделей выполняется на имеющемся ускорителе в нерабочее время, когда система аналитики не нагружена. Основная статья затрат приходится на оплату труда команды.

Требуемая команда

Роль	Занятость	Замечание
Инженер машинного обучения	Полная	Критическая позиция. Без её закрытия пилот не начинается
Аналитик данных	Полная на фазах 0 и 1	Аудит и подготовка данных
Эксперт-закупщик	Четверть занятости	Постановка задачи, оценка рекомендаций, приёмка

Роль	Занятость	Замечание
Владелец продукта от бизнеса	Четверть занятости	Принятие решений на контрольных точках

Состав команды приведён поимённо по ролям не для полноты изложения. В предыдущей попытке запустить эту инициативу работа остановилась не из-за данных и не из-за бюджета, а из-за отсутствия в команде людей с нужными навыками. Поэтому закрытие позиции инженера машинного обучения вынесено в условие начала работ.

Зависимость от качества данных

Наивысшая среди всех рассмотренных инициатив. Три конкретных изъяна, каждый из которых по отдельности достаточен для получения бесполезного результата:

- история продаж искажена периодами отсутствия товара, из-за чего модель обучается на продажах, а не на спросе, и систематически занижает прогноз по дефицитным позициям;
- дубли в справочнике номенклатуры дробят историю одного товара на несколько коротких рядов, непригодных для прогнозирования;
- неразмеченные акции воспринимаются моделью как изменение тенденции, и всплеск спроса переносится на будущие периоды.

Именно поэтому фаза 0 вынесена отдельно и завершается контрольной точкой. Формулировка, которую считаю правильным произнести прямо: **я не начну этот пилот, пока не увижу результаты аудита данных**. Инициатива с наибольшим эффектом одновременно является наиболее чувствительной к качеству данных, и запускать её вслепую означает потратить квартал и получить ноль.

Критерии успешности пилота

Критерием является не точность модели, а **решение закупщика**. Модель с превосходной точностью, рекомендациям которой не следуют, экономического результата не даёт.

Критерий	Целевое значение
Доля рекомендаций, принятых закупщиком без изменений	не ниже 60 процентов
Оборачиваемость запасов по пилотной категории против контрольной	улучшение не менее чем на 10 процентов
Доля отсутствующих в продаже позиций в пилотной категории	снижение не менее чем на 20 процентов
Ошибка прогноза против текущего порядка планирования	улучшение не менее чем на 15 процентов

Что запускается параллельно. Инициатива А, ассистент разработчика 1С, запускается одновременно, поскольку не требует дополнительных вложений в оборудование и даёт видимый результат за 4-6 недель. Это существенно для сохранения доверия к направлению, пока длительный пилот по закупкам проходит свои контрольные точки.

Приложение. Что уже реализовано и проверено

Задание допускает ответ в виде документа. Тем не менее к работе приложен действующий образец системы: описание архитектуры проверяется запуском, а не принимается на слово.

Проверено запуском, а не заявлено в описании:

[+] Развёртывание одной командой: docker compose up -d
[+] Демонстрационное хранилище: 14 витрин, данные за 7 месяцев
[+] Права доступа настроены и проверены самопроверкой скрипта:
 доступ к базовым таблицам закрыт ПРОЙДЕНО
 витрины схемы mart доступны для чтения ПРОЙДЕНО
[+] Оба примера вопросов из задания выполнены под учётной записью только для чтения:
 динамика продаж по регионам за 3 месяца получена
 подразделения с фактом ниже плана на 10% получены
[+] 52 автоматические проверки, все проходят
[+] Набор из 25 бизнес-вопросов, проверка целостности проходит
[+] Непрерывная интеграция: стиль, типы, проверки, сборка пакета
[+] Автоматический выпуск версий и отслеживание обновлений библиотек

Рисунок 5. Состояние образца на момент сдачи

Проверки, подтверждающие утверждения из документа

Каждое существенное утверждение архитектуры закрыто автоматической проверкой. Ниже приведены те из них, которые проверяют не работу кода, а именно проектные решения.

Проверка	Что подтверждает
Цикл исправления запроса	Отказ проверки возвращается модели с указанием причины, и модель переписывает запрос
Ограничение числа попыток	Число повторов ограничено, а имя закрытого объекта не попадает в сообщение пользователю
Обработка ошибки СУБД	Текст ошибки уходит модели для исправления, но не показывается пользователю
Отказ как допустимый исход	Вопрос вне охвата витрин приводит к обоснованному отказу, а не к придуманному запросу
Отсутствие случайности при формировании SQL	Прогон контрольного набора воспроизводим
Неизменность постоянной части подсказки	Кэширование префикса работает, вопрос не попадает в кэшируемую часть
Ограничение объёма, передаваемого модели	В модель уходит не более 100 строк независимо от размера результата
Выбор графика правилом	Обращения к модели для выбора вида графика не происходит
Шесть сценариев нарушения	Каждый отсекается, и отказ происходит по верной причине, а не случайно

Фактически измеренное качество

Набор из 25 бизнес-вопросов прогнан на развёрнутом стенде. Приведённые ниже значения получены измерением, а не расчётом.

Условия замера существенны для истолкования. Измерение выполнено на модели Qwen2.5-Coder-7B, работающей на процессоре без графического ускорителя, поскольку на машине разработки его нет. Предлагаемая архитектура рассчитана на Qwen3-30B-A3B на RTX

5090. Разница между моделью на 7 миллиардов параметров и моделью класса 30 миллиардов на задачах формирования SQL составляет, по опубликованным сравнениям, от 15 до 25 процентных пунктов.

Величина	Измерено	Целевое	Замечание
Доля верных ответов	60,0%	70%	15 из 25. Разрыв объясняется размером модели
Запросы без повторов	76,0%	85%	Прошли проверку безопасности с первой попытки
Среднее число повторов	0,04	0,3	Лучше целевого в семь раз. Рубежи защиты почти не отклоняют запросы, то есть не мешают работе
Полнота отказов	100%	90%	3 из 3. Система ни разу не придумала ответ на вопрос, данных для которого нет
Время ответа, медиана	85,7 с	8 с	Целиком объясняется работой на процессоре
Время ответа, 95-й процентиль	162,3 с	20 с	То же

Разбор по категориям вопросов

Категория	Результат	Истолкование
Простые агрегации	5 из 5	Основной сценарий использования закрыт полностью
Неотвечаемые вопросы	3 из 3	Самая ценная строка таблицы: при недостатке данных система молчит, а не выдумывает
Ранжирование, топ-N	2 из 3	Приемлемо
План и факт	2 из 4	Ошибки в форме результата, а не в выборе витрины
Фильтр и период	2 из 5	Основная слабость. Разбор причин приведён ниже
Динамика во времени	1 из 3	Требуется оконных функций, ожидаемо трудна для модели этого размера
Неоднозначные	0 из 2	Модель задавала уточняющий вопрос вместо ответа по умолчанию

Что показал разбор причин

Сопоставление сформированных запросов с эталонными выявило, что провалы вызваны не ошибками модели, а **пробелами в постановке**. Три примера.

- Включительность границ периода не была задана.** Эталон применяет условие «меньше либо равно» к правой границе, модель применяла строгое «меньше». Расхождение в один день.
- Значение выражения «прошлый месяц» не было определено.** Модель понимала его как последние 30 дней, эталон подразумевал предыдущий календарный месяц целиком.
- Форма ответа при заданном фильтре не была описана.** На вопрос о выручке одного региона модель добавляла регион в группировку и возвращала таблицу из одной строки вместо одного числа.

Каждый из этих вопросов задал бы и живой аналитик, получив такую постановку. Правила формирования запроса дополнены соответствующими пунктами.

Отдельно о риске подгонки. Правка правил по итогам замера на том же наборе создаёт возможность нарисовать любую цифру. Защита здесь не в намерениях, а в характере правок: ни одно добавленное правило не описывает конкретный вопрос набора, все они устраняют общие неоднозначности постановки. Признаком подгонки было бы правило вида «при вопросе о

Северо-Западе не группировать по региону», такого нет. Объективная проверка состоит в пополнении набора новыми вопросами: если рост качества на них сохраняется, правила общие.

Замечание о честности изложения

Отбор витрин в образце выполнен сравнением основ слов, а не моделью эмбедингов BGE-M3, описанной в архитектуре. Основание практическое: модель BGE-M3 занимает около двух гигабайт, из-за чего проверки в среде непрерывной интеграции не смогли бы работать, а образец нельзя было бы запустить на машине без графического ускорителя. В коде оставлена точка замены, интерфейс совпадает.

Существенно другое: полнота отбора вынесена в отдельную измеряемую величину. Замена упрощённого отбора на модель эмбедингов проверяется числом, а не оценивается на глаз. На текущем наборе проверок нужная витрина попадает в выборку в 8 случаях из 8.

Исходный код, набор проверок и порядок развёртывания:

github.com/devAsmodeus/dwh-copilot